

Simulacija 2D nestišljivog strujanja fluida pomoću fizički informisanih neuronskih mreža i neuronskih operatora

Lid-driven cavity problem

Miloš Pavlović, Filip Lalović, Gordan Đurić

Projekat iz mašinskog učenja

11. jul 2026.

- 1 Uvod
- 2 Postavka problema
- 3 Generisanje podataka
- 4 Prva arhitektura: neuronska mreža
- 5 Trening i rezultati
- 6 Ekstrapolacija po Reynoldsovom broju
- 7 Druga arhitektura: Neuronski operatori

Zašto uopšte simuliramo fluide?

Fluidi (vazduh i voda) su svuda oko nas – a često želimo unaprijed znati kako će se kretati:

- vremenska prognoza i kretanje vazdušnih masa,
- aerodinamika automobila, aviona i zgrada,
- protok krvi kroz krvne sudove, hlađenje elektronike, ...

Kako to radimo danas?

Ponašanje fluida opisuju **jednačine strujanja**. Da bismo predvidjeli kretanje, te jednačine rješavamo na računaru – to zovemo *numerička simulacija strujanja* (CFD).


Problem: takve simulacije su **spore i skupe** – za svaki novi slučaj (nova brzina, nova viskoznost, ...) sve se mora računati iznova.

Lid-driven cavity – šta je to?

Zamislite kvadratnu kutiju napunjenu fluidom:

- Gornja stranica – **poklopac** – *klizi* u stranu konstantnom brzinom.
- Ostale tri stranice su **nepomične**.
- Trenje između poklopca i fluida „vuče” fluid za sobom i stvara **vtlog** – kružno kretanje unutar kutije.

To je **lid-driven cavity** („kutija sa pokretnim poklopcem”) – jednostavan, ali klasičan *testni primjer* u dinamici fluida.



Šta rješavamo?

Cilj

Predvidjeti polje **brzine** $u = (u, v)$ i **pritiska** p u svakoj tački kutije, bez pokretanja klasične (spore) CFD simulacije za svaki novi slučaj.


- Umjesto da iznova rješavamo jednačine, želimo model koji uči **operator rješenja** – preslikavanje
 $(\text{parametri strujanja, pozicija } (x, y), \text{ vrijeme } t) \mapsto (u, v, p)$.
- Jednom istreniran, model daje rješenje **gotovo trenutno**.
- Kao „tačan odgovor” (*ground truth*) za učenje koristimo podatke dobijene klasičnim CFD solverom (*OpenFOAM* / *icoFoam*).

Formalna postavka – geometrija i granični uslovi

Fluid je zatvoren u **jediničnom kvadratu** $\Omega = [0, 1] \times [0, 1]$.

- **Gornji poklopac** ($y = 1$): $u = (U, 0)$, gdje je $U = 1$.
- **Ostala tri zida**: uslov neproklizavanja (*no-slip*), $u = (0, 0)$.

Kretanje poklopca formira **glavni vrtlog**, a u donjim uglovima nastaju slabiji **sekundarni vrtlozi**.



Formalna postavka – jednačine strujanja

Ponašanje fluida opisuju **nestišljive Navier–Stokes jednačine**:

Jednačina kontinuiteta (očuvanje mase)

$$\nabla \cdot \mathbf{u} = \frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} = 0$$

Jednačine količine kretanja (očuvanje impulsa)

$$\frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} = -\nabla p + \frac{1}{\text{Re}} \nabla^2 \mathbf{u}$$

gdje je $\mathbf{u} = (u, v)$ brzina, p pritisak (bezdimenziono, $\rho = 1$), a

$$\text{Re} = \frac{UL}{\nu}$$

Rejnoldsov broj – odnos inercijalnih i viskoznih sila (U – brzina poklopca, L – dužina stranice, ν – kinematska viskoznost).
Veći $\text{Re} \Rightarrow$ složenije strujanje.


Zašto baš ovaj problem?

- **Standardni benchmark** u dinamici fluida – jednostavna geometrija, precizno definisani granični uslovi, dobro poznata rješenja za poređenje.
- **Bogata fizika** uprkos jednostavnosti: glavni vrtlog, sekundarni vrtlozi u uglovima, singularnosti pritiska u gornjim uglovima.
- **Parametrizacija Rejnoldsovim brojem:** mijenjanjem Re dobijamo čitavu familiju rješenja – idealno za učenje *operatora rješenja*.
- Podaci se lako generišu klasičnim CFD solverom (*icoFoam* / OpenFOAM) i služe kao referentna istina (*ground truth*).

Odakle nam „tačan odgovor”? – CFD simulacija

Referentne podatke (*ground truth*) generišemo klasičnim CFD solverom **OpenFOAM** (*icoFoam*); cijeli postupak je **automatizovan** (`generate_dataset.py`):

- 1 Za zadati Re računamo viskoznost $\nu = \frac{UL}{Re}$.
- 2 Iz **YAML konfiguracije** popunjavamo OpenFOAM šablone (granični uslovi, viskoznost, mreža, vrijeme).
- 3 `blockMesh` pravi mrežu, `icoFoam` rješava nestišljive Navier–Stokes jednačine **kroz vrijeme**.
- 4 **PyVista** čita rezultat, sječe 2D ravan i vadi (u, v, p) u centrima ćelija.
- 5 Snimamo u CSV – jedan red $= (t, Re, x, y, u, v, p)$.



Parametri simulacije i podjela skupa

Domen i simulacija

- Jedinični kvadrat $[0, 1]^2$, brzina poklopca $U = 1$.
- Mreža: 64×64 (trening), 128×128 (test).
- Solver icoFoam: nestišljiv, laminaran, tranzijentan.
- Vrijeme: $\Delta t = 0,01$, do $T = 10$ (razvijeno strujanje).

Reynoldsov broj

- $Re \in [100, 1000]$, **50 vrijednosti** (ravnomjerno).
- Svaki $Re \Rightarrow$ jedna simulacija $\Rightarrow$ familija rješenja.

Podjela (bez curenja podataka)

- Stratifikovano **po** Re : **70 / 15 / 15 %** (trening / validacija / test).
- Validacija i test koriste Re **vrijednosti neviđene** tokom treninga.
- Test skup je na **finijoj mreži** (128×128), koja nema zajedničkih tačaka sa mrežom korišćenom za trening.

Zašto podjela po Re ?


Model mora *interpolirati/ekstrapolirati* na nove režime strujanja, a ne samo pamtit viđene tačke.

Uzorkovanje po regionima i umanjeni skupovi

Puna CFD mreža daje **previše** tačaka, i to **neravnomjerno korisnih**. Zato uzorkujemo **po regionima** (`sample_by_region`):

- **Poklopac** (jedini netrivialan GU): zadržavamo **sve** tačke.
- **Zidovi** (no-slip): umjeren dropout ($\sim 50\%$).
- **Unutrašnjost** (jezgro vrtloga, redundantna): jak dropout ($\sim 85\%$).

Dodatno pravimo **umanjene podskupove** – **1 %**, **5 %**, **10 %** podataka – za kasniji eksperiment „koliko podataka je zaista dovoljno”.




Gušće uz granice, rjeđe u unutrašnjosti.

Osnovni model: potpuno povezana mreža (MLP)

Prvi pristup – **obična neuronska mreža** koja uči *direktno iz podataka*:

- **Ulaz:** (t, Re, x, y)
- **Izlaz:** (u, v, p)
- Arhitektura (`models.py`): **4 skrivena sloja $\times$ 256 neurona**, aktivacija **Tanh**, potpuno povezani slojevi.



Funkcija gubitka – samo podaci

$$\mathcal{L}_{\text{data}} = \frac{1}{N} \sum_{i=1}^N \|(u, v, p)_i^{\text{pred}} - (u, v, p)_i^{\text{true}}\|^2$$

Ograničenje: model samo „reprodukuje” CFD podatke – **nema garancije da poštuje fizičke zakone**, naročito tamo gdje podataka nema.

Ključna ideja: fizičko ograničenje (NavierStokesLoss)

Rješenje ne treba samo da *odgovara podacima*, nego i da **zadovoljava jednačine strujanja**. Pomoću **automatskog diferenciranja** računamo izvode izlaza po ulazima $(u_x, u_y, u_{xx}, \dots)$ i mjerimo koliko mreža „krši” Navier–Stokes jednačine:

Reziduali (treba da budu ≈ 0)

$$f_c = u_x + v_y, \quad f_u = u_t + uu_x + vu_y + p_x - \frac{1}{\text{Re}}(u_{xx} + u_{yy}), \quad f_v = v_t + uv_x + vv_y + p_y - \frac{1}{\text{Re}}(v_{xx} + v_{yy})$$

Ukupni gubitak (podaci + fizika)

$$\mathcal{L} = \mathcal{L}_{\text{data}} + c_{\text{phys}} \underbrace{\left(\overline{f_c^2} + \overline{f_u^2} + \overline{f_v^2} \right)}_{\mathcal{L}_{\text{fizika}}}, \quad c_{\text{phys}} = 0,1$$

Fizika djeluje kao **regularizacija** i **dodatni izvor informacija** – usmjerava model ka fizički mogućim rješenjima čak i bez podataka u toj tački. Ovo je *fizički informisana neuronska mreža* (PINN).

Postavka

- Ulazi i izlazi normalizovani **Z-score**-om.
- Optimizator: **Adam**.
- Raspored učenja: **ReduceLROnPlateau** (smanjuje korak kad validacija stagnira).
- Do **300 epoha**, batch veličine 256.

Praćenje

- Zasebno pratimo **ukupni**, *data* i *fizički* gubitak.
- Po svakom pokretanju čuvamo **checkpoint** i krive gubitka (runs/).
- Model biramo po najboljem **validacionom** gubitku.

Podsjetnik: podjela bez curenja podataka

Trening / validacija / test su razdvojeni **po Rejnoldsovom broju** – model se testira na Re vrijednostima koje *nije vidio* (v. sekciju o generisanju podataka).

Strategija treninga: Centralni izrez i hibridni gubitak

Maksimalno iskorišćenje fizike uz redukciju podataka:

- **Centralni izrez (Cutout):** Iz unutrašnjosti („sredine”) kutije potpuno uklanjamo podatke u obliku kvadrata određene površine (**25%, 49% i 64%**).
- **Novi hiperparametar:** Pored težinskog koeficijenta c_{phys} , veličina ovog geometrijskog izreza postaje parametar za testiranje modela.



Šematski prikaz domena sa centralnim izrezom.

Formulacija gubitka tokom treninga

- **Data loss ($\mathcal{L}_{\text{data}}$):** Računa se standardnim MSE-om **samo na preostalim zadatim podacima** (dominantno u slojevima oko granica i zidova).
- **Physics loss ($\mathcal{L}_{\text{fizika}}$):** Računa se na kolokacionim tačkama koje pokrivaju cio domen, primoravajući mrežu da rekonstruiše fluid u „praznom” prostoru.

Metrike računamo na **originalnoj (nenormalizovanoj) skali**, po komponenti i ukupno:

- R^2 (koeficijent determinacije), **MSE**, **MAE**, relativna L^2 greška.
- **Brzine** (u, v): visok R^2 – model dobro rekonstruiše polje brzina.
- **Pritisak** p : niži R^2 i veća maksimalna greška – očekivano zbog neodređenosti do konstante i singularnosti u uglovima.

Zaključak o modelu

Fizički informisana mreža uspješno uči **familiju rješenja** parametrizovanu Reynoldsovim brojem i daje rezultate **gotovo trenutno** nakon treninga.

Gubitak na podacima ($\mathcal{L}_{\text{data}}$)

- Računa se na **kompletnom validacionom skupu** podataka.
- Evaluacija obuhvata i unutrašnjost izreza (prazninu) kako bi se formalno ocijenila sposobnost modela da rekonstruiše polje strujanja u oblastima bez trening labela.

Gubitak na fizici ($\mathcal{L}_{\text{fizika}}$)

- Računa se nezavisno, isključivo na **kolokacionim tačkama** uzorkovanim unutar validacionog koraka.

Disjunktnost kolokacionih tačaka

- Skupovi kolokacionih tačaka u treningu i validaciji su **striktno disjunktni**.
- Ova disjunktnost je parametarski garantovana upotrebom **različitih Reynoldsovih brojeva** ($\text{Re}_{\text{train}} \cap \text{Re}_{\text{valid}} = \emptyset$).

Eksperimentalni rezultati (Izrez 25%)

Tabela 1: Ukupne metričke performanse u zavisnosti od koeficijenta c_{phys}

Težina fizike	c_{phys}	Region domena	Ukupni R^2	MAE	MSE	Relativna L^2
0.00	(Čist ML)	Izrez (Sredina)	0.9542	0.0134	0.0004	0.2073
		Ostatak domena	0.9744	0.0070	0.0005	0.1598
0.01		Izrez (Sredina)	0.9728	0.0104	0.0003	0.1596
		Ostatak domena	0.9773	0.0062	0.0004	0.1505
0.05		Izrez (Sredina)	0.9791	0.0097	0.0002	0.1399
		Ostatak domena	0.9762	0.0066	0.0004	0.1544
0.10		Izrez (Sredina)	0.9777	0.0098	0.0002	0.1446
		Ostatak domena	0.9753	0.0067	0.0004	0.1572
0.50	(Najbolji)	Izrez (Sredina)	0.9827	0.0084	0.0002	0.1275
		Ostatak domena	0.9758	0.0066	0.0004	0.1554
1.00		Izrez (Sredina)	0.9800	0.0090	0.0002	0.1369
		Ostatak domena	0.9703	0.0078	0.0005	0.1724

Ključni rezultat: Uvođenjem fizike ($c_{\text{phys}} = 0.50$), R^2 skor unutar izreza raste za **2.99%** (sa 0.9542 na 0.9827).

Tabela 2: Ukupne metričke performanse u zavisnosti od koeficijenta c_{phys}

Težina fizike	c_{phys}	Region domena	Ukupni R^2	MAE	MSE	Relativna L^2
0.00	(Čist ML)	Izrez (Sredina)	0.8649	0.0209	0.0012	0.3594
		Ostatak domena	0.9668	0.0089	0.0007	0.1818
0.01		Izrez (Sredina)	0.9232	0.0162	0.0007	0.2709
		Ostatak domena	0.9696	0.0079	0.0007	0.1738
0.05		Izrez (Sredina)	0.9451	0.0140	0.0005	0.2292
		Ostatak domena	0.9715	0.0078	0.0006	0.1684
0.10		Izrez (Sredina)	0.9481	0.0132	0.0005	0.2227
		Ostatak domena	0.9712	0.0076	0.0006	0.1692
0.50	(Najbolji)	Izrez (Sredina)	0.9587	0.0118	0.0004	0.1987
		Ostatak domena	0.9685	0.0089	0.0007	0.1769
1.00		Izrez (Sredina)	0.9571	0.0121	0.0004	0.2026
		Ostatak domena	0.9677	0.0091	0.0007	0.1791

Ključni rezultat: Uvođenjem fizike ($c_{\text{phys}} = 0.50$), R^2 skor unutar izreza raste za **10.84%** (sa 0.8649 na 0.9587).

Tabela 3: Ukupne metričke performanse u zavisnosti od koeficijenta c_{phys}

Težina fizike	c_{phys}	Region domena	Ukupni R^2	MAE	MSE	Relativna L^2
0.00	(Čist ML)	Izrez (Sredina)	0.4565	0.0446	0.0051	0.7247
		Ostatak domena	0.7582	0.0432	0.0064	0.4883
0.01		Izrez (Sredina)	0.4332	0.0449	0.0053	0.7401
		Ostatak domena	0.7595	0.0418	0.0064	0.4869
0.05		Izrez (Sredina)	0.4227	0.0451	0.0054	0.7469
		Ostatak domena	0.7632	0.0398	0.0063	0.4832
0.10		Izrez (Sredina)	0.4548	0.0440	0.0051	0.7259
		Ostatak domena	0.8504	0.0281	0.0040	0.3841
0.50		Izrez (Sredina)	0.5274	0.0408	0.0044	0.6759
		Ostatak domena	0.8427	0.0286	0.0042	0.3938
1.00	(Najbolji)	Izrez (Sredina)	0.6028	0.0380	0.0037	0.6195
		Ostatak domena	0.8539	0.0279	0.0039	0.3796

Ključni rezultat: Uvođenjem fizike ($c_{\text{phys}} = 1.00$), R^2 skor unutar izreza raste za **32.05%**

Eksperiment: ekstrapolacija na neviđene režime strujanja

Do sada je model *interpolirao* unutar trening opsega. Sada testiramo mnogo teži scenario – **ekstrapolaciju** na Reynoldsove brojeve *izvan* opsega treninga.

- **Trening:** podaci samo za $Re \in [100, 1000]$ (isti umanjeni skup od 1%, bez centralnog izreza).
- **Test:** $Re \in \{1200, 1400, 1600, 1800, 2000\}$ – **potpuno izvan** trening opsega.

Pitanje

Da li fizičko ograničenje pomaže modelu da *pogodi* strujanje pri Reynoldsovim brojevima koje nikada nije vidio – gdje čist ML nema referentne podatke na koje bi se oslonio?

Trening i testiranje

Trening (labele samo za $Re \in [100, 1000]$)

- Isti **MLP PINN** (4×256 , Tanh) i **hibridni gubitak** $\mathcal{L} = \mathcal{L}_{\text{data}} + c_{\text{phys}} \mathcal{L}_{\text{fizika}}$.
- Data loss:** MSE na labeliranim CFD tačkama – *cio domen* (ovdje **nema** centralnog izreza).
- Physics loss:** na **8192 kolokacionih tačaka** uzorkovanih po domenu, pri *trening* Rejnoldsovim brojevima.
- Optimizator **Adam** ($\text{lr} = 10^{-3}$), **ReduceLROnPlateau**, **300 epoha**, batch 256, Z-score normalizacija.
- Ablacija:** $c_{\text{phys}} \in \{0, 0.01, 0.05, 0.1, 0.5, 1\}$, svih 6 modela isti seed.
- Najbolji model biramo po **validacionom data** gubitku (validacija = neviđeni *Re* *unutar* opsega).

Test (ekstrapolacija, $Re = 1200 - 2000$)

- Nove OpenFOAM simulacije** za svaki test *Re*, na **finijoj mreži** 128×128 (trening je bio 64×64) – dakle i *druge* prostorne tačke.
- $\sim 901\,000$ tačaka ukupno; nijedan *Re* nije viđen u treningu.
- Metrike (R^2 , MAE, relativna L^2) računamo na **originalnoj (nenormalizovanoj) skali**, po komponenti i ukupno.
- Poredimo **najbolji PINN** ($c_{\text{phys}}=0.1$) sa modelom sa $c_{\text{phys}}=0$ na *istim* test tačkama.

Suština

Trening „zna” fiziku samo do $Re = 1000$; na testu tražimo da je *produži* na jače strujanje koje nikada nije vidio.

Tabela 4: Metrike na cijelom ekstrapolacionom skupu ($\text{Re} = 1200 - 2000$)

c_{phys}	Ukupni R^2	R_u^2	R_v^2	R_p^2	MAE	Rel. L^2
0.00	0.8043	0.7921	0.8239	0.7958	0.0199	0.4421
0.01	0.8175	0.8042	0.8392	0.8041	0.0187	0.4270
0.05	0.8202	0.7944	0.8641	0.7773	0.0180	0.4238
0.10	0.8357	0.8136	0.8743	0.7821	0.0163	0.4051
0.50	0.8204	0.7789	0.8910	0.7639	0.0173	0.4236
1.00	0.8311	0.7993	0.8860	0.7713	0.0159	0.4108

Ključni rezultat: Uvođenjem fizike ($c_{\text{phys}} = 0.10$) ukupni R^2 raste sa **0.8043** na **0.8357** (+3.9%) – i to na Reynoldsovim brojevima *izvan* trening opsega.

Ekstrapolacija – fizika pomaže sve više što je Re dalji

Tabela 5: R^2 po Reynoldsovom broju: najbolji PINN ($c_{\text{phys}} = 0.10$) vs. čist ML ($c_{\text{phys}} = 0$)

Re	1200	1400	1600	1800	2000
PINN (fizika, $c=0.10$)	0.951	0.906	0.842	0.764	0.677
Bez fizike ($c=0$)	0.946	0.894	0.814	0.715	0.605
Dobit od fizike	+0.005	+0.012	+0.028	+0.049	+0.072

Ključni zaključak

Što se više udaljavamo od trening opsega (granica na $Re = 1000$), to je **doprinos fizike veći** – od +0.005 tik iznad granice do +0.072 pri $Re = 2000$. Fizičko ograničenje djeluje kao **stabilizator** u nepoznatom režimu, gdje čist ML brže gubi tačnost.

Druga arhitektura: GINO (Graph-Informed Neural Operator)

Klasičan FNO zahtijeva strogo uniformnu mrežu. Da bismo radili sa nepravilno uzorkovanim podacima i dropout-om, koristimo **GINO** hibridnu arhitekturu:

1. Enkoder: Od nepravilnih tačaka do uniformne mreže

- **MeshGNN**: Preko k -NN grafa i *EdgeConv* mehanizma uči lokalnu geometriju i interakciju bliskih čestica fluida.
- **GNOEncoder**: Projektuje neregularne tačke grafa na skrivenu, uniformnu latentnu mrežu dimenzija $S \times S$.

2. Globalni solver: Frekvencijski domen (FNO2d)

Brza Furijeova transformacija (*fft2*) prebacuje signal u domen frekvencija. Spektralne konvolucije množe niske modove kompleksnim težinama, učeći globalne zakone strujanja (*vrtloge*) nezavisno od rezolucije.

3. Dekoder: Kontinuirani povratak na željene koordinate

GNODecoder interpolira procesirane informacije sa latentne mreže direktno na kontinualne upitne tačke (*query positions*).

Hvala na pažnji!